

Big Data, Machine Learning, and the Social Sciences: Fairness, Accountability, and Transparency

A ideia do artigo é falar sobre 4 temas, e que estão relacionados a justiça (fairness), responsabilidade (accountability) e transparência (transparency) em aprendizagem de máquina, com o objetivo de fazer com que esses temas sejam discutidos em sociedade. Os temas abordados são dados, questões modelos e conclusões (findings).

Dados

Big data pode ser definido segundo como “um largo, diverso, complexo, longitudinal, e/ou distribuído conjunto de dados gerado a partir de instrumentos, sensores, interação com a internet, email, vídeo, fluxo de cliques, e/ou qualquer outra fonte digital disponível.”

[1]

Porém, há uma distinção entre o conceito de *big data* e o grande volume de dados capturado em análises físicas é o fato que em *big data* os dados são sobre pessoas, isto é, sobre suas preferências, opiniões e interações. Além do fato de esses dados mostrarem os fenômenos sociais, por armazenarem informações o comportamento social das pessoas, eles são capazes de fazer isso de forma granular (granularity), ou seja mostrar os dados sobre uma pessoa e sua atividades de forma individual.

Por serem informações tão pessoais, o uso destas informações trás a tona questões relacionadas à ética, privacidade, viés (bais), justiça (fairness), e inclusão. Esses assuntos não fazem parte da expertise de um profissional de análise de dados.

Por isso, a autora sugere que os profissionais que englobam esta área podem aprender bastante sobre a área de ciência social computacional. Esta é uma área interdisciplinar das

ciências sociais, estatísticos e cientistas da computação. A função do cientista social é que produzir contexto e conhecimento vital para questões importantes da pesquisa, fonte de dados, métodos de aquisição e interpretação de dados, enquanto a função do estatístico e cientista da computação é contribuir com modelos matemáticos e ferramentas computacionais.

Dois fatores têm de ser levados em consideração ao se analisar esses grandes conjuntos de dados: a questão da granularidade dos dados e o fato que podem conter várias bases de dados menores dentro deste grande conjunto de dados. Não levar esses fatores em consideração pode trazer problemas de viés, justiça, e inclusão.

Levar esses dois fatores em consideração trás uma mudança de perspectiva ao analisar os dados. A autora sugere algumas questões sobre problemas computacionais para reflexão e que reforçam a importância de um cientista social como parte do processo de análise desses dados, são eles: Como podemos construir modelos para tirar conclusões precisas sobre dados heterogêneos? Devemos desenvolver modelos que agregam, talvez inspirados em utilização de múltiplos classificadores, que consideram separadamente subconjuntos menores ou aninhados desses dados? Podemos fazer isso sem violar questões de ética e privacidade? E, se sim, como podemos construir modelos precisos para esses subconjuntos aninhados e diversificados?

Questões

Com uma quantidade razoável de dados é possível ver uma sinal grosseiro de granularidade, mas ele não reflete toda a base, principalmente sobre dados de minorias. Uma boa granularidade, talvez não seja possível de alcançar apenas

utilizando técnicas computacionais. É necessário um profissional com experiência em saber quais questionamentos devem ser feitos ao analisar os dados e onde encontrar essas respostas, reafirmando assim a figura do cientista social.

O processo tradicional de “data first” e “method first” acabam resultando em padrões de granularidade grosseiras que refletem a maioria e ignora os padrões mais difíceis e minoritários. Outro problema desses processos é que as bases de dados tendem a ser as cuja aquisição é mais fácil, como o twitter. O problema está no fato que essas bases de dados concentram um conjunto específico da sociedade, resultando assim em modelos que levam em consideração majoritariamente um único subconjunto da população.

Uma técnica diferente, empregada pelos cientistas sociais, pode ser utilizada para fazer essas análises a de priorizar as questões sociais acima da viabilidade dos dados. Esta pode ser uma boa oportunidade para utilizar questões que priorizem as minorias, o viés, a justiça e a inclusão. Esses dados podem não ser tão fáceis de achar, tornando necessário a utilização de técnicas de agregação e curadoria de informação que quando combinados com modelos e ferramentas são capazes de gerar dados granulares de boa qualidade, levando em conta os que anteriormente eram difíceis de observar. Esses processo, embora mais trabalhoso, resulta em dados de melhor qualidade que permitem uma análise que reflete mais eficazmente o mundo real.

Modelos

Na tentativa de se classificar modelos de um modo que atinja os analistas de dados e os cientistas sociais computacionais pode se classificar os modelos em 3 tipos: Modelos de predição, de explanação e de exploração.

Modelo de predição, analisado principalmente por cientistas da computação, são modelos que tentam prever uma informação com

base nos dados de uma base. Essa informação pode ser algo que ainda vai para acontecer ou preencher algum tipo de dado faltante em um base.

Modelo de explanação. Análise tipicamente realizado por cientistas sociais tentam responder “o porquê” dos dados se comportar daquele jeito. Essas explicações podem ser comparadas com teorias sociais e conclusões de análises feitas anteriormente.

Modelo de exploração. Comumente realizado por ambas as áreas, tem por objetivo fazer uma primeira análise nos dados tentando descobrir que tipo de informação pode ser retirada daquela base de dados.

Como modelos de análises explanatórias e exploratórias tendem a anteceder a predição é importante se preocupar com esses modelos e com os possíveis problemas de viés ou algum tipo de injustiça que se encontrem neles, pois esses erros serão propagados para o modelo de predição.

Ao se analisar a exatidão do modelo é importante levar em consideração detalhes sobre como ele está analisando, pois caso o modelo acerte todos os exemplos das classes majoritárias e erre todos nas minoritárias é um modelo que ainda pode ser muito melhorado. Corrigir erros de viés, justiça e inclusão não apenas melhora o modelo como trás o tipo de ganho pro modelo que realmente importa para a sociedade.

Um modo de prevenir este tipo de erro é por mostrar o nível de confiança que o modelo tem de sua resposta, pois para todo modelo de predição ocorrerão respostas com nível de certeza menor que outros. Esse tipo de informação pode ser útil ao se analisar qual nível de confiança deve ser dado ao tentar se analisar um dado mais fraco.

Conclusões

Para se ter um bom resultado em um modelo é importante a participação de um especialista na área em questão. O mesmo ocorre

quando os dados são de seres humanos vivendo em sociedade. Este profissional é importante pois ele é capaz de diferenciar as interpretações baseadas em estereótipos e enviesadas, das que têm base teórica e acadêmica. Além disso, eles são mais capacitados para estar atento a fatores humanos que influenciam tanto o processo de construção da conclusão como o da conclusão final.

No ponto de vista da transparência e responsabilidade é importante ter divulgado sobre a área, tanto através de códigos disponíveis para serem utilizados como de artigos publicados mostrando resultados de pesquisas realizadas.

Análise crítica

O artigo mostrou que big data trata sobre dados da sociedade e por isso é importante especialistas neste domínio para melhor representar as suas características. Mostrou também que devemos tratar esses dados como heterogêneos sendo possível dividi-los em subconjuntos para análises mais detalhadas e precisas.

Além disso, mostrou que devemos levar em conta a justiça, responsabilidade e transparência ao se analisar os dados e mostrou procedimentos que podemos utilizar para tornar esses dados mais justos, aumentando assim sua relevância e precisão em relação ao mundo real. Podemos fazer por meio de diversas formas que passam pela fase de aquisição dos dados, levando em conta que às vezes é necessário pesquisas em outras bases e em fontes diferentes para encontrar dados que aumentem, não só a eficácia do modelo, mais também, a representatividade da sociedade. Além disso, durante a análise dos dados os modelos de análise exploratória e explanatória tem de ser levados em consideração, pois visto que suas análises são utilizadas na predição, seu viés e justiça serão irão influenciar o modelo de predição, podendo torná-lo injusto e enviesado.

Este tipo de cuidado permite que tenhamos modelos mais eficazes e mais justos e visto que se trata informações que envolvem pessoas seu desempenho pode impactar, positiva ou negativamente, na sociedade.

Referências

- [1] <https://www.nsf.gov/pubs/2012/nsf12499/nsf12499.htm>